📈 나만의 데이터로 미래를 예측하다

Orange3 선형 회귀 실습 보고서

— 두 변수의 관계를 스스로 찾아 예측 모델 만들기 —

학년 반 번호	1학년	이름	김수현	제출일	26 . 09 . 23 .

🎯 미션 우리 주변에는 '하나가 늘면 다른 하나도 규칙적으로 변하는' 관계가 많습니다. 공부 시간과 성적, 기온과 아이스크림 판매량, 팔로워 수와 좋아요 수처럼요. 이번 활동에서는 내가 직접 고른 두 변수(x, y)의 데이터를 모아 산점도를 그리고, 노코딩 머신러닝(ML) 도구 Orange3로 선형 회귀 예측 모델을 만든 뒤, 그 예측이 믿을 만한지 스스로 검증합니다.

🏆 이 보고서는 수행평가① **"Orange3 선형회귀 탐구"** 입니다. 만점 **30**점 · 기본점수**9**점 세 영역 각 10점(영역1·영역2·영역3)으로 채점합니다. ※ **AI(생성형 AI 포함)** 활용은 원칙적으로 금지합니다.

영역 1	데이터 이해 및 회귀식 추정	[10점]

📋 평가요소 (배점 근거)

① 선형 관계가 나타나는 탐구 주제·데이터를 목적에 맞게 선정하고, 독립·종속 변수의 관계를 올바르게 파악하였는가? → 1-1

② 산점도를 근거로 회귀식(y=ax+b)을 합리적으로 추정하였는가? → 1-2-1·1-2-2

③ 기울기·절편의 의미를 데이터 맥락에서 설명하였는가? → 1-3

1-1 탐구 주제와 데이터 정하기 (내 탐구 설계)

💡 어떤 관계를 예측해 볼까? 아래는 아이디어일 뿐입니다. 관심 분야에서 자유롭게 골라도 좋고, 직접 새로운 주제를 만들어도 됩니다.

분야	예시 주제 (독립변수 x → 종속변수 y)
일상·소비	기온 → 아이스크림(또는 음료) 판매량 · 광고비 → 매출액
학습·생활	공부 시간 → 시험 점수 · 수면 시간 → 집중도 자기평가 점수
사회·미디어	팔로워 수 → 게시물 좋아요 수 · 영상 길이 → 조회수
과학·환경	음료 온도 → 얼음 녹는 시간 · 용수철에 매단 무게 → 늘어난 길이
스포츠·건강	키 → 몸무게 · 연습 시간 → 기록(초·점수)

✅ 좋은 데이터의 조건

· 두 변수 모두 숫자(연속형)이고, 하나가 변하면 다른 하나도 대체로 함께 변하는 관계일 것

· 데이터 개수는 최소 8개 이상 (많을수록 회귀선이 안정적)

· 직접 측정·설문하거나 공공데이터(KOSIS·기상자료개방포털 등)에서 수집 — 출처를 반드시 기록

탐구 주제	시도별 자동차 및 트레일러 제조업 종사자 수와 출하액의 관계
독립변수 **x**	종사자수(명)
종속변수 **y**	출하액(백만원)
데이터 출처	https://kosis.kr/statHtml/statHtml.do?orgId=101&tblId=DT_1FS1001_S&conn_path=I2
예상 관계	x가 커지면 y는 증가할 것이다. 그렇게 생각한 이유:인력이 많아지면 생산량이 늘어나 그에따른 출하액도 많아질 것이라 예상함

1-2-1 내 훈련 데이터 입력하기 (train.csv)

💡 수집한 훈련 데이터를 구글 시트나 엑셀에 입력하고 train.csv로 저장하세요. 첫 행은 변수 이름(x, y)으로 합니다.

독립변수 **x** (종사자수)	종속변수 **y** (출하액)
335,771	248,511,081
409	42,637
10,861	7,408,241
15,457	6,908,313
15,702	11,025,250
17,319	16,963,817
2,034	741,232
53,918	60,889,045
1,301	673,104
73,344	58,408,644

2,765	1,485,431
15,611	10,540,633
42,090	28,933,062
17,472	8,500,119
679	232,871
30,590	16,587,874
36,219	19,170,808

📷 구글 시트 또는 엑셀에 입력한 훈련 데이터 화면을 캡처하여 붙여넣기

	A	B
1	종사자수 (명)	출하액 (백만원)
2	335,771	248,511,081
3	409	42,637
4	10,861	7,408,241
5	15,457	6,908,313
6	15,702	11,025,250
7	17,319	16,963,817
8	2,034	741,232
9	53,918	60,889,045
10	1,301	673,104
11	73,344	58,408,644
12	2,765	1,485,431
13	15,611	10,540,633
14	42,090	28,933,062
15	17,472	8,500,119
16	679	232,871
17	30,590	16,587,874
18	36,219	19,170,808
19		

1-2-2 규칙을 찾아 회귀식 손으로 추정하기

🧠 x가 일정하게 커질 때 y는 얼마씩 변하나요? 표에서 규칙을 찾아 직선의 식 y = a x + b 로 손으로 추정해 보세요.

x가 한 단위 커질 때 y는 약 750만큼 증가한다. → 기울기 a ≈ 750 , 절편 b ≈ -300000 . 따라서 y = 750 x - 300000 로 예상한다.

1-3 기울기와 절편의 의미 해석

기울기 a는 이 데이터에서 무엇을 뜻하나요? 절편 b는 x=0일 때 무엇을 의미하나요? (내 주제의 맥락으로 설명)

기울기는 종사자 수가 증가할때 늘어나는 예상 출하액의 변화량이다. 절편 b는 종사자수가 0명일때 출하액이므로 현실적으로 불가능한 값이다.

영역 2 | Orange3 예측 모델 구성 | [10점]

📋 평가요소 (배점 근거)

① train-test 데이터를 적절히 구성하였는가? → 1-2(train)·2-1(test)

② 워크플로우(File→Scatter Plot→Linear Regression→Predictions)를 올바르게 연결하였는가? → 2-2

③ 모델의 예측값을 산출하고 실제값(손 계산)과 비교하였는가? → 2-3

2-1 내 테스트 데이터 만들기 (test.csv)

💡 훈련 데이터 범위 안에서 x값 5개 정도를 골라 테스트 데이터(test.csv)를 만드세요. y열은 비워 둡니다.

독립변수 x	종속변수 y (비움)
1000	?
10000	?
25000	?
45000	?
65000	?

2-2 Orange3 워크플로우 구성하기

📌 워크플로우 순서

① File 위젯 → train.csv 불러오기 (이름: train data)

② Data Table 위젯 연결 → 데이터 확인

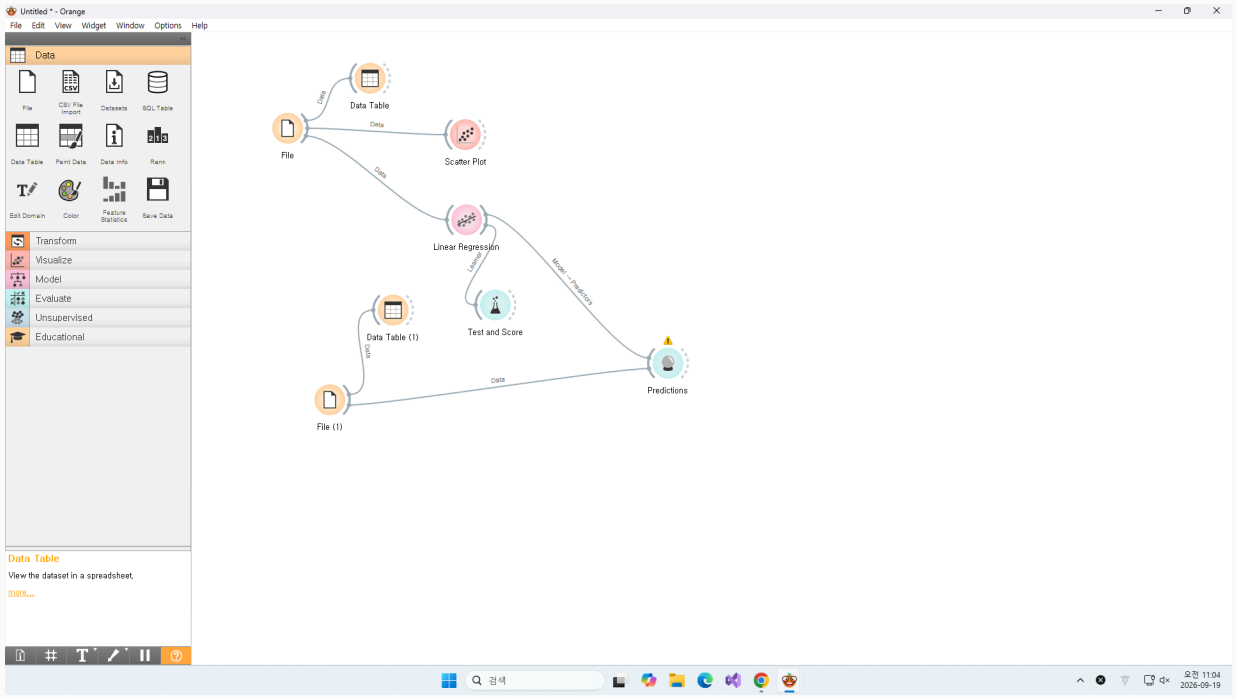
③ Scatter Plot 위젯 연결 → 산점도 확인 (x축: 독립변수, y축: 종속변수)

④ Linear Regression 위젯 연결 → 모델 학습

⑤ 새 File 위젯 → test.csv 불러오기 (이름: test data)

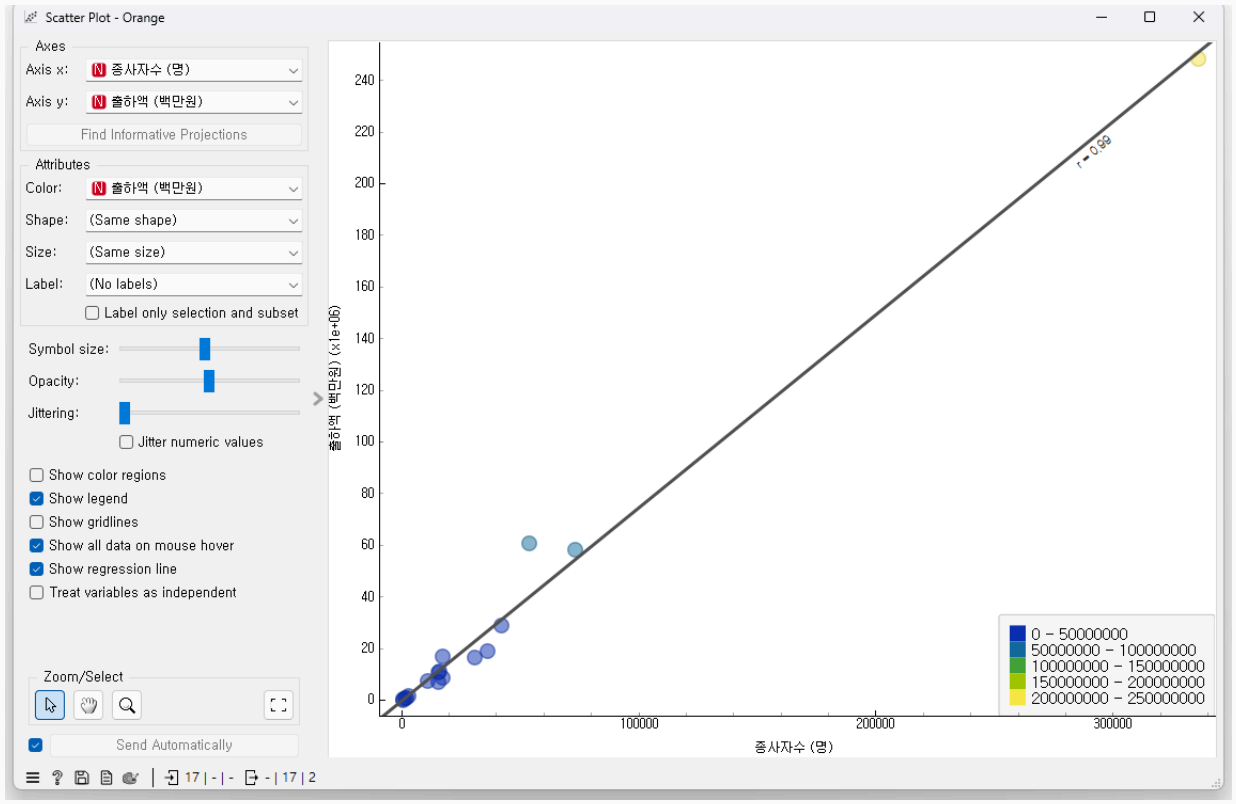
⑥ Predictions 위젯 → 모델 + 테스트 데이터 연결

Orange3 캔버스의 전체 워크플로우를 캡처



산점도 확인 및 관찰

Scatter Plot 산점도 화면 캡처 (x축·y축 라벨이 보이도록)

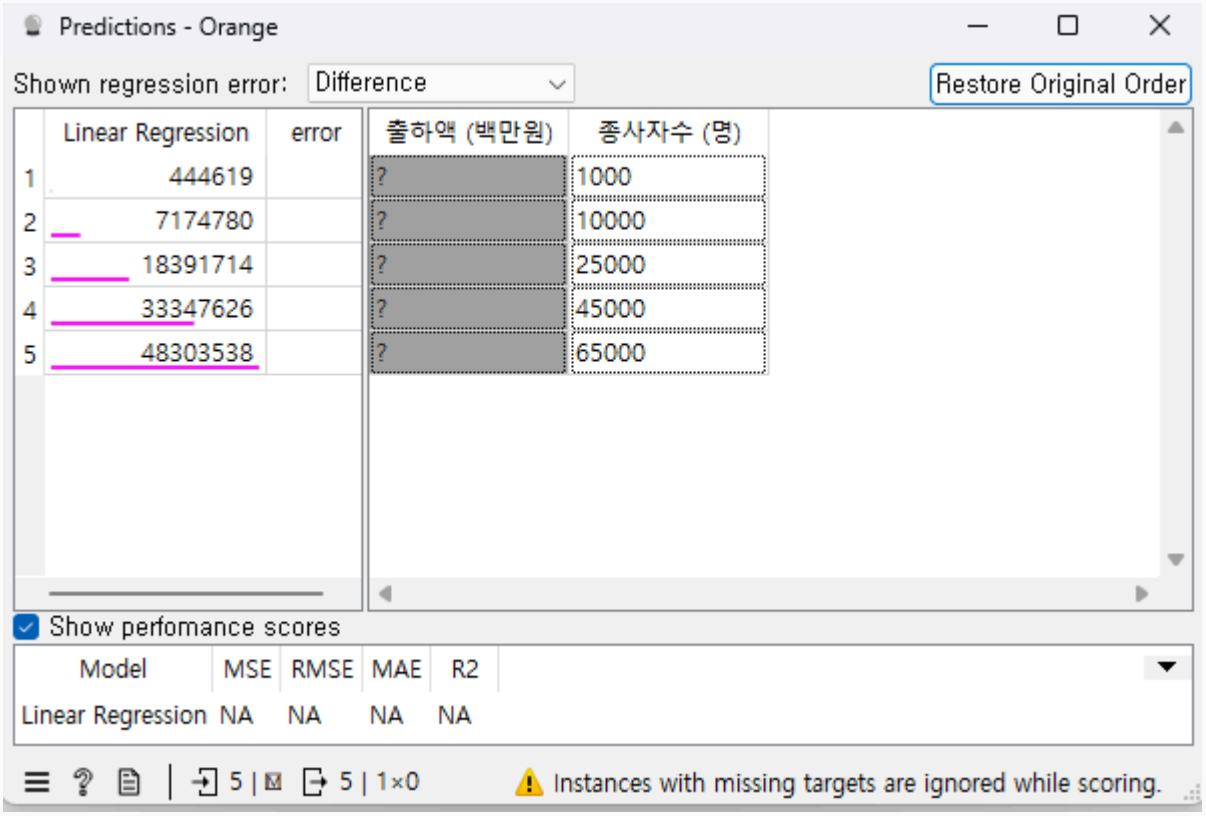


왼쪽 아래 -> 오른쪽 위

두 변수는 양의 관계를 가지고 있고 강도가 강하다.

2-3 예측 결과 비교 (내 손 계산 vs Orange3)

📷 Predictions 위젯의 예측 결과 화면을 캡처



x 값	내가 계산한 예측값 (y=ax+b)	Orange3 예측값
1000	450000	444619
10000	7200000	7174780
25000	18450000	18391714
45000	33450000	33347626
65000	48450000	48303538

영역 3 결과 검증 및 해석 [10점]

📋 평가요소 (배점 근거)

① 회귀선과 평가지표(R²·MAE·RMSE)로 예측 결과의 타당성을 검증하였는가? → 3-1

② 정비례·반비례 등 관계의 방향과 의미를 데이터 맥락에서 해석하였는가? → 3-2

③ 모델의 한계(외삽의 위험)를 탐구하고, 활동을 통해 배운 점을 성찰하였는가? → 3-3·3-4

3-1 회귀선으로 타당성 검증

내 손 계산값과 Orange3 예측값이 비슷한가요? 예측 점들이 산점도의 회귀선 위/근처에 놓이나요? 이 모델이 데이터의 규칙을 잘 학습했다고 판단한 근거를 쓰세요.

비슷하다. 예측 점들이 회귀선 근처에 놓인다. 이는 모델이 두 데이터 간의 선형적 규칙을 잘 반영해 학습했다는걸 보여주어 모델이 데이터의 규칙을 잘 학습했다고 판단한다.

3-1-2 모델 평가지표로 신뢰도 검증 (Test and Score · 심화)

🌟 **(심화) Test and Score**로 모델의 신뢰도를 '숫자'로 검증하기

① **[Evaluate] → [Test and Score]** 위젯을 추가한다.

② **train data(File)**를 **Data**로, **Linear Regression**을 **Learner**로 각각 연결한다.

③ 평가 방법은 **Cross validation(**교차검증**,** 기본값**)**으로 두고 아래 세 지표를 읽어 기록한다.

(MSE·MAPE도 함께 나오지만 **R²·MAE·RMSE**에 집중**. RMSE = MSE**의 제곱근**)**

평가지표	내가 기록한 값	이 값이 뜻하는 것 **(**내 해석**)**
R² (결정계수)	0.962	회귀 모델의 타당성이 높음
MAE (평균오차)	11222237.42	실제 출하액과 예측값에 약 1122만(백만원)의 오차가 있음
RMSE	18485739.37	평균적인 예측 오차는 약 1849만(백만원)임

위 지표로 볼 때 내 모델은 얼마나 믿을 만한가요? 아래를 근거로 설명하세요.

① R²는 1에 얼마나 가까운가? (예측이 데이터를 잘 설명하는가)

② RMSE가 MAE보다 크다면, 그 이유는 무엇일까? (크게 빗나간 이상치)

③ [심화] Test and Score 점수는 '처음 보는 데이터로 시험 본' 교차검증 점수입니다. 전체 데이터에 그냥 맞췄을 때(훈련)보다 왜 조금 낮을까요?

이 모델은 매우 믿을만 하다. R2가 0.962로 1에 아주 가까우므로 예측이 데이터를 잘 설명한다고 볼 수 있다. Rmse가 mae보다 큰 것은 일부 지역 중에 종사자 수 대비 출하액이 유독 크게 튀는 이상치가 있기 때문이라고 볼 수 있다. 또한 교차검증 점수가 훈련 점수보다 낮게 나온 것은 훈련 점수는 임 학습한 데이터로 평가해서 높게나오지만 교차검증은 새로운 데이터로 평가해 일반화 성능을 측정하는 것이므로 점수가 조금 더 낮게 나온다.

3-2 결과 해석 — 숫자 뒤의 의미

x와 y는 정비례·반비례 중 어느 관계인가요? 기울기의 크기가 뜻하는 바는? 이 예측 결과를 실생활에서 어떻게 활용할 수 있을지 내 주제의 맥락으로 해석하세요.

X와y는 정비례 관계이고 기울기의 크기는 종사자 1인당 평균 노동 생산량으로 해석 할수 있다.

이 회귀식을 이용하면 특정 지역에 자동차·트레일러 제조업 종사자를 얼마나 배치했을 때 어느 정도의 출하액(생산 실적)을 기대할 수 있는지 사전에 가늠할 수 있다. 이는 지자체나 기업이 신규 산업단지 조성·인력 채용 계획을 세울 때 투입 인력 대비 기대 생산 규모를 예측하는 기초 자료로 활용될 수 있고, 산업공학적으로는 인력 투입과 생산 산출 간의 효율성(생산성)을 지역별로 비교·평가하는 데도 쓰일 수 있다.

3-3-1 한계 탐구 — 극단값 실험 (외삽의 위험)

🤔 학습 데이터 범위를 크게 벗어난 x값을 회귀식에 넣으면 예측이 현실적으로 말이 될까요? 외삽(Extrapolation)의 위험을 확인해 봅시다.

극단적인 **x** 값	모델 예측값 **y**	현실적으로 가능한가**?**
0	-1373500백만원	불가능
200만	약 1466조	불가능

선형회귀는 x,y값의 들어갈 수 있는 숫자가 무한하기 때문에 극단적인 수치를 넣게 된다면 현실성에 한계가 생긴다. 선형회귀를 신뢰는 일상적인 기업 규모 범위 안에서만 유효하다.

3-3-2 활동 성찰

📝 활동을 돌아보며 이번 활동에서 '어떤 문제 → 어떻게 해결 → 무엇을 배웠는지'와, 선형 회귀로 예측할 때 주의할 점(3-3의 외삽 실험과 연결)을 함께 정리하세요. 성실히 쓰면 세특(세부능력 및 특기사항) 작성의 좋은 소재가 됩니다.

📝 활동 성찰 — '어떤 문제 → 어떻게 해결 → 무엇을 배웠는지' 흐름으로 쓰면 세특 작성의 좋은 소재가 됩니다.

산업단지 전체를 지역별로 묶어 분석했을 때는 R^2가 0.3 수준으로 낮아서 업종이 뒤섞여 있는 것이 원인임을 파악하고 자동차 및 트레일러 제조업으로 범위를 좁혀 재분석했다. 그 결과 R^2가 0.962까지 크게 향상되어, 변수를 하나의 기준(업종)으로 통일하는 것이 회귀분석의 설명력을 높이는 핵심임을 배웠다. 또한 교차검증 점수가 훈련 점수보다 낮게 나오는 것을 보며, 모델이 새로운 데이터에도 잘 일반화되는지가 신뢰도의 진짜 기준임을 깨달았다. 이를 통해 데이터 범위 설정이 분석 결과에 미치는 영향과 통계 지표를 비판적으로 해석하는 태도를 기를 수 있었다.

📚 핵심 개념 요약

· 지도학습 : 정답(레이블)이 있는 데이터로 모델을 훈련시키는 방법

· 회귀(Regression) : 연속적인 숫자 값을 예측하는 문제 유형

· 선형 회귀 : y = ax + b 직선으로 데이터의 패턴을 표현하는 알고리즘

· 기울기 a의 부호 : a>0이면 양의 관계(정비례), a<0이면 음의 관계(반비례)

· 외삽(Extrapolation)의 위험 : 학습 데이터 범위를 벗어난 예측은 신뢰하기 어려움

· 결정계수(R^2) : 모델이 데이터를 설명하는 비율(0~1). 단순 선형회귀에서는 상관계수의 제곱($R^2=r^2$)

· MAE / RMSE : 예측 오차의 크기(작을수록 좋음). RMSE는 큰 오차(이상치)에 더 민감

· 교차검증(Cross validation) : 데이터를 나눠, 학습에 쓰지 않은 부분으로 평가 → 모델의 '진짜 실력(일반화 성능)' 측정

· 훈련 vs 검증 성능 : 본 데이터엔 잘 맞고(훈련), 처음 보는 데이터엔 조금 못 맞음(검증). Test and Score 값이 검증 성능

🔎 수행평가 채점표 (교사 기입용)

채점 기준: 아래 참고

※ 저작권·데이터 윤리 미준수, 평가 윤리 미준수, AI 활용 금지 원칙 위반 등 부적절 상황 발생 시 해당 영역 0점 처리.

평가영역	배점	채점 기준 (해당 점수에 ○)	획득 점수
[영역1] 데이터 이해 및 회귀식 추정	10점	10 · 8 · 6 · 4	
[영역2] Orange3 예측 모델 구성	10점	10 · 8 · 6 · 4	
[영역3] 결과 검증 및 해석	10점	10 · 7 · 4 · 1	
합계	**30**점	기본점수 9점	**/ 30**